

OTT 유저 이탈 위험 예측 및 리텐션 최적화 프로젝트

1 차 머신러닝 프로젝트 보고서

Machine Learning Project Report

1. 프로젝트 개요

본 프로젝트는 OTT 서비스 이용자의 인구통계, 구독 정보, 이용 행태 데이터를 기반으로 구독 해지 위험도를 예측하는 머신러닝 기반 서비스이다.
예측 결과는 안정, 주의, 위험 3개 등급으로 제공되며, 최종적으로 Flask 웹 화면에서 기존 사용자 조회와 직접 입력 예측이 가능하도록 구현하였다.

클래스	등급	해석
0	안정	구독 유지 가능성이 높은 사용자
1	주의	이탈 가능성이 일부 존재하는 사용자
2	위험	구독 해지 가능성이 높은 사용자

2. 개발 목표

- OTT 이용자의 이탈 위험도를 머신러닝으로 예측한다.
- 안정 / 주의 / 위험 등급과 클래스별 확률을 함께 제공한다.
- Oracle DB 데이터와 학습 모델을 연결하여 기존 사용자를 조회한다.
- 직접 입력 기능을 통해 새로운 사용자 조건에 대한 예측도 가능하게 한다.
- Flask UI를 통해 비전공자도 결과를 쉽게 확인할 수 있도록 구성한다.

3. 사용 데이터와 주요 변수

데이터는 Oracle DB의 F1_USER_DATASET 테이블을 사용하였다. 사용자의 기본 정보, 경제/가구 정보, 구독 정보, 이용 행태, 콘텐츠 이용 성향 등을 모델 입력값으로 사용하였다.

구분	주요 변수
사용자 기본 정보	GENDER, AGE_GROUP
경제/가구 정보	INCOME_GROUP, FAMILY_TYPE
구독 정보	MONTHLY_FEE_CODE, HAS_AD_PLAN, AD_INTENT
이용 행태	USE_FREQUENCY, WEEKDAY_TIME_CODE, WEEKEND_TIME_CODE
콘텐츠/서비스 이용 성향	SEARCH_VIEW, RECOMMEND_VIEW, BINGE_WATCH, DEVICE_COUNT, OTT_SERVICE_COUNT 등

코드값은 별도 code_meanings.py 파일로 정리하여 성별, 연령대, 소득 구간, 요금제, 이용 빈도, 이용 시간대 등의 의미를 사람이 읽기 쉬운 형태로 해석할 수 있게 하였다.

4. 전처리 및 학습 방식

- TARGET_RISK가 없는 행은 제거하고 타깃값은 정수형으로 변환하였다.
- 학습 데이터와 테스트 데이터는 8:2 비율로 분리하였다.
- 클래스 분포 유지를 위해 stratify 옵션을 사용하였다.
- 결측값은 SimpleImputer(strategy="median")로 중앙값 대체하였다.
- 모델은 Pipeline 구조로 구성하여 전처리와 예측 과정이 같은 흐름으로 동작하게 하였다.

5. 최종 모델과 피처 선정

최종 모델은 ExtraTreesClassifier를 사용하였다. 트리 기반 모델은 코드화된 범주형 데이터와 비선형 패턴을 처리하기 좋고, 별도의 스케일링 부담이 적어 이번 데이터 구조에 적합하다고 판단하였다.

최종 피처는 SAFE 피처 조합에 USE_FREQUENCY를 추가한 형태이다. 실험 과정에서 이용 빈도는 OTT 이탈 위험을 판단하는 데 매우 중요한 신호로 확인되었다.

구분	내용
최종 피처 방향	인구통계 + 구독 정보 + 이용 행태 + 콘텐츠 성향 + USE_FREQUENCY

6. 실험 결과 요약

초기 실험에서는 월소득, 이용 시간대, 구독 정보 등만으로는 주의/위험 사용자를 충분히 구분하기 어려웠다. 특히 위험군 또는 주의군의 재현율이 낮아 실제 이탈 가능성이 있는 사용자를 안정으로 보내는 문제가 있었다. 이후 USE_FREQUENCY를 포함한 최종 피쳐 조합으로 변경하면서 전체 예측 성능과 균형 정확도가 개선되었다. 최종 성능은 다음과 같이 정리된다.

항목	결과	해석
Accuracy	약 0.9089	전체 예측 중 약 90.89%가 정답
Balanced Accuracy	약 0.8084	클래스 불균형을 고려해도 약 80.84% 수준
위험군 예측	개선되었으나 완벽하진 않음	위험 사용자를 안정으로 보내지 않도록 주의 등급 흡수 방향이 중요

정리하면, 최종 모델은 단순 정확도뿐 아니라 안정/주의/위험 클래스를 비교적 균형 있게 분류하는 방향으로 개선되었다. 다만 위험군을 100% 잡아내는 모델은 아니므로, 실제 서비스에서는 위험 예측을 절대 판단이 아니라 사전 선별 신호로 활용하는 것이 적절하다.

7. 구현 결과

구현 항목	내용
모델 학습 코드	Oracle DB에서 데이터 로드 후 ExtraTreesClassifier 학습
모델 저장	joblib으로 모델, 피쳐 목록, 모델명을 함께 저장
기존 유저 예측	USER_SEQ 입력 시 DB에서 사용자 정보를 조회하고 위험도 예측
직접 입력 예측	사용자가 입력한 값으로 안정/주의/위험 등급 예측
Flask UI	메인 화면, 기존 유저 예측, 직접 입력 예측, 결과 화면 구성

8. 프로젝트 진행 중 핵심 판단

- USE_FREQUENCY는 실제 이용 충성도와 가장 직접적으로 연결되므로 최종 피쳐에 포함하였다.
- 전체 정확도보다 위험/주의 사용자를 놓치지 않는 방향을 더 중요하게 보았다.
- 데이터 규모와 프로젝트 목적상 딥러닝보다 트리 기반 머신러닝이 더 적합하다고 판단하였다.
- 단순 콘솔 예측에서 끝내지 않고 Flask 웹 서비스 형태로 확장하였다.

9. 한계와 개선 방향

한계	개선 방향
데이터가 실제 서비스 로그 전체를 반영하지는 못함	시청 이력, 결제 실패, 앱 접속 빈도 등 실제 로그 추가
위험군 예측이 완벽하지 않음	Recall 개선, 임계값 조정, 클래스 가중치 추가 실험
예측 사유가 모델 내부 해석과 완전히 같지는 않음	SHAP 등 설명 가능한 AI 기법 적용
현재는 정적 DB 데이터 기반 예측에 가까움	최근 활동 데이터를 반영하는 주기적 재학습 구조 도입

10. 최종 결론

이번 1차 머신러닝 프로젝트에서는 OTT 사용자의 구독 해지 위험도를 안정, 주의, 위험 등급으로 예측하는 모델과 웹 서비스를 구현하였다.

데이터 로드, 전처리, 피쳐 선정, 모델 학습, 성능 평가, 모델 저장, 예측 코드, Flask UI 연동까지 머신러닝 서비스의 기본 흐름을 완성하였다.

최종 모델은 Accuracy 약 90.89%, Balanced Accuracy 약 80.84%를 기록하였다. 위험군 예측에는 아직 개선 여지가 있지만, 이탈 가능성이 있는 사용자를 사전에 선별하는 보조 도구로는 충분한 의미가 있다.